DR. THEJUS MAHAJAN

Klinische Daten · Registerdaten · Biostatistik in R

+49 1525 9697629 · @ thejus.mahajan@uni-hamburg.de · github.com/thejusmahajan
Reventlowstraße 17, 22605 Hamburg · *30.09.1992 · Uneingeschränkte Arbeitserlaubnis für Deutschland



PROFIL

Promovierter Physiker für Aufgaben mit klinischen Daten und Registerdaten in R. Ab sofort verfügbar; Umzug innerhalb Deutschlands möglich.

- **Registerdaten:** produktive R-Pipeline eines Qualitätsregisters (143.000+ Datensätze, rund 300 Kliniken) von 1.834 auf 1.349 Zeilen verschlankt, Ausgabe nach jeder Änderung byte-identisch.
- **Klinische Endpunkte:** Erfolgskriterien für 26 Interventionstypen definiert; 241 Korrekturregeln und 16 Erfolgskriterien in Konfigurationsdateien ausgelagert.
- **Biostatistik:** Weiterbildungsmodul Angewandte Biostatistik in R mit Note 1,0; R-Paket mit 9 Funktionen (`devtools::check()` ohne Fehler).

Berufswechsel 2025–2026: Vollzeit-Weiterbildung (Angewandte Biostatistik 1,0), Praktikum mit klinischen Daten, Gastwissenschaftler am Hereon, HLRS-Kurs zu HPC und KI.

BERUFSERFAHRUNG UND WEITERBILDUNG

Biostatistik und klinisches Datenmanagement (Praktikum)

HealthTwiSt GmbH, bei Dr. Andreas Busjahn

02/2026 - 04/2026 · Berlin, Deutschland

Service-Unternehmen für die statistische Auswertung klinischer, genetischer und wissenschaftlicher Studien sowie Datenmanagement.

- Produktive Auswertungspipeline (R) des DeGIR[1]-Qualitätsregisters überarbeitet (143.000+ Datensätze, rund 300 Kliniken). Validierung: Ausgabe nach jeder Änderung mit `identical()` gegen die Referenz geprüft, byte-identisch.
- Registerdatensätze auf Patientenebene geprüft; klinische Endpunkte (Erfolg/Teilerfolg/Misserfolg) für 26 Interventionstypen definiert; SIR-Komplikationsgrading.
- 241 Korrekturregeln und 16 Erfolgskriterien aus dem Code in Konfigurationsdateien ausgelagert und dokumentiert.
- Zwei bestehende Fehler gefunden und dokumentiert; Ergebnisse bewusst unverändert gelassen.
- R-Paket `degirtools` (roxygen2, `devtools::check()` ohne Fehler); Shiny-Werkzeug zur Datenvalidierung in Eigeninitiative.
- ML-Lehrskripte von caret auf tidymodels umgestellt; Einführungsskript in Quarto neu erstellt.
- *Beurteilung: „sehr große Selbständigkeit, Eigeninitiative und Sorgfalt"; „ein sehr gut geeigneter Kandidat für Positionen im Bereich Biostatistik / Bioinformatik".*

Weiterbildung: Angewandte Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH, Vollzeit

08/2025 - 02/2026 · Berlin, Deutschland

Abgeschlossen 04/2026 (mit Praktikum).

- Angewandte Biostatistik in R, Note 1,0: lineare Modelle mit Interaktionen, logistische Regression, gemischte Modelle, multivariate Verfahren (PCA, Diskriminanz-, Clusteranalyse), Machine Learning (Entscheidungsbäume, Random Forest, Boosting).
- Bioinformatik und Datenbanken (SQL/MySQL, Note 1,4); Programmierung in Python (Note 1,2).
- Next-Generation Sequencing: Abschlussprojekt Nextflow-Pipeline (GitHub).

[1] DeGIR: Deutsche Gesellschaft für Interventionelle Radiologie und minimal-invasive Therapie.

KENNTNISSE

Statistik
Lineare, logistische und gemischte Modelle, multivariate Verfahren (PCA, Diskriminanz-, Clusteranalyse), Random Forest, Boosting, Spark MLlib, LLM-Agenten (Kurs)

Statistische Programmierung
R (tidyverse, tidymodels), SAS-Grundlagen (Coursera), Python (Pandas, NumPy, scikit-learn, PyTorch, PySpark), SQL/MySQL

Qualität & Dokumentation
Validierung gegen Referenzausgaben, Code-Review, R-Pakete (roxygen2, devtools), Quarto, Git/GitHub, Datenschutz klinischer Daten, FAIR-Prinzipien

Werkzeuge
RStudio, Shiny, Linux, Bash, PBS-Batch-Jobs auf GPU-Cluster, MS Office

SPRACHEN

Englisch ●●●●●
Fließend (C1)

Deutsch ●●●○○
B1 (Goethe-Zertifikat), B2-Prüfung am 10.12.2026 angemeldet

Französisch ●●○○○
Grundkenntnisse

Malayalam ●●●●●
Muttersprache

Tamil, Hindi ●●●○○
Gute Kenntnisse

WEITERE KURSE

Deployable Data Analysis & AI Pipelines with HPC
HLRS Stuttgart | 09–10/2026, 50 Stunden; Abschlussprüfung bestanden, Zertifikat vom 05.11.2026

IBM AI Engineering Professional Certificate
Coursera | laufend; Modul *Deep Learning with PyTorch* abgeschlossen 08/2026

Introduction to Supercomputing
FZ Jülich | 11/2025

Gastwissenschaftler
Helmholtz-Zentrum Hereon, Ökosystemmodellierung
05/2025 - 10/2025 Geesthacht, Deutschland

Hamburger Modellierungsprojekt nach Vertragsende weitergeführt, parallel zur Weiterbildung ab 08/2025: Modellrahmen fertiggestellt, Simulationsdaten für das Manuskript vorbereitet.

Stellensuche & Deutschkurs

02/2025 - 04/2025 Hamburg, Deutschland

Deutschkurs; Goethe-Zertifikat B1 im Juni 2025 bestanden.

Wissenschaftlicher Mitarbeiter (Postdoc)
Universität Hamburg, Institut für marine Ökosystem- und Fischereiwissenschaften
08/2021 - 01/2025 Hamburg, Deutschland

- Individuenbasiertes Modell des Cyanobakterien-Lebenszyklus (IBM-CLC) entwickelt und an Labormessungen der experimentellen Kolleginnen und Kollegen angepasst; Manuskript in der Endphase.
- Simulationssoftware von Fortran nach Python/JAX portiert (GPU, Google Colab); NetCDF-Daten auf einem Linux-Cluster verarbeitet.
- Lehre im BSc-Kurs Marine Ecosystem Modelling (2022–23); Gastvorlesung im MSc-Programm.
- Elternzeit 01/2024 – 12/2024.

Umzug nach Deutschland

04/2021 - 07/2021 Hamburg, Deutschland

Umzug von Indien nach Deutschland; Stellensuche.

Physik-Tutor & Schachtrainer
Freiberuflich / Tutorwaves Solutions Inc.
10/2018 - 03/2021 Kerala, Indien

Einzelunterricht in Physik und Schach.

Doktorand
Université Paris-Saclay, ISMO
10/2015 - 09/2018 Orsay, Frankreich

Kollisionsexperimente am Tandem-Beschleuniger Orsay: Datenerfassung, Kalibrierung und Qualitätskontrolle von Multidetektor-Daten; Beitrag von Verzweigungsverhältnissen zur KIDA-Datenbank.

OPEN-SOURCE-PROJEKTE

Interpretierbarkeit neuronaler Netze
07/2026 – heute
Python/PyTorch-Analyse des Netzes von Leela Chess Zero (lc0-interpretability). 345 automatisierte Tests, zentrale Prüfungen mutationsgetestet. Zwei stille Fehler in der eigenen Analyse gefunden und öffentlich korrigiert.

Sequenz-Pipeline (Nextflow DSL2)
Abschlussprojekt der Weiterbildung, 01–03/2026
Hepatitis-Delta-Referenzsequenzen über NCBI (Entrez Direct) geladen, mit MAFFT aligniert und mit trimAl getrimmt; vier Prozesse, Werkzeuge in Conda-Umgebungen (hepatitis-delta-pipeline).

KURSPROJEKTE (HLRS)

Verteilte Datenanalyse (Apache Spark MLlib)
Große Betriebsdaten der S-Bahn Stuttgart (Linie S1) mit Wetterdaten verknüpft; Regressionsmodelle (RMSE von 2,63 auf 1,89 Min.) und Random-Forest-Klassifikation (27 Stationen) in Batch-Jobs auf dem Cluster.

Multi-GPU Deep Learning (PyTorch DDP)
Trainingsskript von einer auf 4 GPUs (Tesla V100 SXM2) umgestellt; ca. 4.600 Bilder/s, 80,1 % Validierungsgenauigkeit nach 7 Epochen. CNN-Vergleich GPU gegen CPU: 4,8-facher Speedup pro Epoche.

LLM-Agenten & Tool-Calling (MCP)
Abschlussprüfung: MCP-Tool-Server (Starlette/SQLite) erweitert; zwei Open-Weight-LLMs als Agenten verglichen und jede Antwort gegen SQL-Referenzabfragen geprüft; eine erfundene Umsatzzahl per Tracing auf den verursachenden Agentenschritt zurückgeführt.

PUBLIKATIONEN

Erstautor: Mahajan et al., *J. Phys. B: At. Mol. Opt. Phys.* 52, 195204 (2019).

Insgesamt vier begutachtete Zeitschriftenartikel und zwei begutachtete Konferenzbeiträge (2017–2020).

Google Scholar

AUSBILDUNG

Promotion in Lasern, Molekülen und atmosphärischer Strahlung
Université Paris-Saclay, ISMO
10/2015 - 09/2018 Orsay, Frankreich

Anwendung: Astrochemie. Betreuerin: Dr. Karine Béroff.

M.Sc. in Physik
National Institute of Technology Calicut, Indien
07/2012 - 12/2014 Calicut, Indien

Mit Auszeichnung (CGPA 8,71/10).

Forschungsprojekt: Theoretische Atomphysik
IIT Mandi (Dr. Hari Varma)
02/2015 - 08/2015 Mandi, Indien

Theoretische Physik.

B.Sc. in Physik
University of Calicut, Indien
06/2009 - 04/2012 Thrissur, Indien

B+ (CGPA 3,49/4,0).