

THEJUS MAHAJAN PH.D.

Computational Scientist · Klinische Datenpipelines · Biostatistik · Bioinformatik

📞 +49 1525 9697629 · @ thejus.mahajan@uni-hamburg.de · thejusmahajan.github.io
📍 Reventlowstraße 17, 22605 Hamburg · 📅 *30.09.1992 (Talikulam, Indien) · 👤 Verheiratet · Staatsangehörigkeit: Indisch
Arbeitsberechtigung für Deutschland vorhanden
🌐 linkedin.com/in/thejusmahajan · 🐙 github.com/thejusmahajan · 🎓 Google Scholar

PROFIL

- Computational Scientist (Promotion, Post-doc) mit abgeschlossener Weiterbildung in **angewandter Bioinformatik und Biostatistik** sowie Praxiserfahrung im klinischen Datenpipeline-Engineering.
- HealthTwist GmbH (Praxisphase): Refactoring einer Produktions-R-Pipeline für das DeGIR-Qualitätsregister (143.000+ Patientendatensätze, ~300 Kliniken) mit **byte-identisch verifizierter Ausgabe nach jeder Änderung**; Erstellung des R-Pakets `degirtools` und eines Shiny-Dashboards.
- Kernkompetenzen: R (tidyverse, Shiny, tidymodels), Python (Pandas, NumPy, PyTorch), SQL, Git, Nextflow.
- Offen für: Klinische Data Science, Biostatistik, Statistical Programming, Klinisches Datenmanagement und Research Software Engineering; offen für Umzug innerhalb Deutschlands. **Ab sofort verfügbar.**

BERUFSPERFAHRUNG

Unabhängige Forschung – Validierung von Deep-Learning-Pipelines Eigenständig, Open Source

📅 07/2026 - heute 📍 Hamburg, Deutschland

Korrektheit und Validierung von Machine-Learning-Analysepipelines

- **Zwei systematische Fehler** in einer Analysepipeline diagnostiziert und behoben, die plausible, aber ungültige Ergebnisse erzeugten – ohne Exception, ohne fehlschlagenden Test. Analyse veröffentlicht, samt öffentlicher Korrektur eigener früherer Ergebnisse.
- Aufbau der Toolchain (Python, **PyTorch**, ONNX) mit automatisierter Testsuite; die Guards sind **mutationsgetestet**, also nachweislich fehlschlagend, wenn die geschützte Logik gebrochen wird.
- Beitrag: *The Mirror in the Machine* (thejusmahajan.github.io)

Klinisches Datenpipeline-Engineering — Praxisphase (Weiterbildung ABI-2025-3)

HealthTwist GmbH

📅 02/2026 - 04/2026 📍 Berlin, Deutschland

Klinische Datenforschung und -entwicklung unter Dr. Andreas Busjahn

- Refactoring einer monolithischen 1.834-Zeilen R-Datenpipeline (tidyverse) für das interventionell-radiologische Qualitätsregister Deutschlands (DeGIR); 143.000+ Patientendatensätze von ~300 Kliniken. Reduktion auf 1.349 Zeilen (–26,5%) mit byte-identischer Ausgabe, verifiziert via `identical()`.
- Externalisierung von 241 Korrekturregeln und 16 Erfolgskriterien in 8 Konfigurations-CSV-Dateien; ermöglicht Bearbeitung durch Nicht-Programmierer.
- Ersetzung von 360 veralteten Funktionsaufrufen in 4 Pipeline-Dateien; Modernisierung auf aktuelle tidyverse-Standards.
- Erstellung des R-Pakets `degirtools` (9 exportierte Funktionen, roxygen2-Dokumentation, `devtools::check()` bestanden) durch Extraktion wiederverwendbarer Logik aus einer 767-Zeilen-Hilfsdatei.
- Entdeckung von 2 vorbestehenden Fehlern durch systematische Codeanalyse; dokumentiert und originales Verhalten für Supervisor-Review beibehalten — Demonstration von Produktionscode-Disziplin.
- Aufbau eines interaktiven R-Shiny-Dashboards (6 Module: Übersicht, Interventionen, Komplikationen, Strahlendosen, Erfolgsraten, Info) mit `plotly`, `DT` und `bslib`. Deployment auf `shinyapps.io` mit einem de-identifizierten, perturbierten Extrakt statt Patientendaten.
- Erstellung von Tidymodels-Lehrmaterialien (Quarto/GitHub) als Ersatz für das veraltete `caret`-Framework für ML-Workflows in R.

Weiterbildung – Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH

📅 08/2025 - 02/2026 📍 Berlin, Deutschland

Angewandte Bioinformatik und Biostatistik

- Programmiermethodik: Shell (BASH), Python (objektorientiert), R.
- Bioinformatik-Datenbanken (NCBI, Biopython, SQL) und Sequenzanalyse.

STÄRKEN

Klinische Datenpipeline-Engineering

Refactoring einer Produktions-Datenpipeline (1.834 Zeilen, 143K Datensätze, ~300 Kliniken) mit 26,5% Codereduktion. Erstellung des R-Pakets `degirtools`. Byte-Level-Verifizierung nach jeder Änderung via `identical()`.

Verifizierung & Korrektheit

Byte-identische Verifizierung jeder Pipeline-Änderung (`identical` mutationsgetestete Guards; zwei stille Korrektheitsfehler im eigenen Code gefunden, behoben und veröffentlicht; zwei bestehende Fehler im Produktionscode dokumentiert statt still geändert.

Biostatistik, Bioinformatik & Reproduzierbare Forschung

Multivariate Analyse (PCA, ANOVA), klinische Ergebnisanalyse, tidymodels-Workflows und Kreuzvalidierung; NGS-Datenanalyse, reproduzierbare Nextflow-Pipelines (DSL2), DSGVO-konforme Datenverarbeitung.

TECHNISCHE FÄHIGKEITEN

Programmierung

R (tidyverse, Shiny, tidymodels), Python (Pandas, NumPy, PyTorch, JAX), SQL / MySQL, Fortran, BASH

Klinische Daten & Biostatistik

Medizinische Registerpipelines, DSGVO-Konformität, multivariate Analyse, PCA, ANOVA, Survival-Analyse-Konzepte, klinische Endpunkte

Dateningenieurwesen

Pipeline-Refactoring, konfigurationsgetriebene ETL, `identical()` Verifizierung, R-Shiny-Dashboards, große Datensätze (HDF5, NetCDF)

Bioinformatik

NGS-Analyse, Nextflow (DSL2), Sequenzanalyse

Maschinelles Lernen

tidymodels- und scikit-learn-Workflows, Kreuzvalidierung, PyTorch, Transformer-Modelle, ONNX-Konvertierung

Werkzeuge

Git/GitHub, Linux/Unix, Linux-Cluster, Conda, LaTeX, Docker-Konzepte

SPRACHEN

Englisch

● ● ● ● ●

Verhandlungssicher (C1)

Deutsch

● ● ● ● ●

B1 (Goethe-Zertifikat), B2 in Vorbereitung

Französisch

● ● ● ● ●

Grundkenntnisse

- NGS-Analysepipelines (Next-Generation Sequencing; Nextflow); Strukturbioinformatik.
- Biostatistik (R): ANOVA, PCA, HCA, multivariate Analyse, Markov-Ketten.
- Abschlussprojekt: Erstellung einer reproduzierbaren Nextflow-(DSL2)-Pipeline für die Sequenzanalyse des Hepatitis-Delta-Virus — automatisierter NCBI-Download, MAFFT-Alignment und trimAl-Trimming mit Conda-verwalteten Abhängigkeiten (🔗 GitHub).

Gastwissenschaftler (parallel zur Weiterbildung ab 08/2025)

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

📅 05/2025 - 10/2025 📍 Geesthacht, Deutschland

Modellierung evolutionärer Prozesse in Meeresökosystemen; Simulation langfristiger Umweltauswirkungen mittels fortgeschrittener Rechenmethoden. Fertigstellung des rechnergestützten Modellierungs-Frameworks und Aufbereitung der Simulationsdaten für eine Peer-Review-Publikation.

Jobsuche & Deutschkurs

📅 02/2025 - 04/2025 📍 Hamburg, Deutschland

Aktive Stellensuche und Erwerb der deutschen Sprache (Goethe-Zertifikat B1).

Wissenschaftlicher Mitarbeiter (Post-doc)

Universität Hamburg, Institut für Marine Ökosystem- und Fischereiwiss.

📅 08/2021 - 01/2025 📍 Hamburg, Deutschland

Marine Ökosystemmodellierung

- Elternzeit von 01/2024 bis 12/2024.
- Modellentwicklung: Entwicklung des "Cyanobacteria Life Cycle" (CLC)-Modells als 0-D-agentenbasierte Formulierung, 1-D gekoppelt in **GOTM-FABM**, für Klimaerwärmungsprojektionen.
- Portierung einer Legacy-Fortran/OpenMP-Engine nach **Google JAX**: Umschreibung jeder Verzweigung pro Agent in vektorisierte, verzweigungs-freie Form für GPU/TPU-Portabilität; ausgeführt auf Google Colab (T4-GPU). Große NetCDF-Datensätze auf einem **Linux-Cluster**.

Berufliche Neuorientierung

📅 04/2021 - 07/2021 📍 Hamburg, Deutschland

Umzug von Indien nach Deutschland und aktive Stellensuche.

Physik-Dozent & Schachtrainer — Freiberuflich / Tutorwaves Solutions Inc., Kerala, Indien · 10/2018 – 03/2021

Doktorand in Astrochemie

Université Paris-Saclay

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Atomkollisionsexperimente, Datenanalyse und Modellierung an der AGAT-Apparatur am Tandem-Beschleuniger Orsay. Analyse von Multidetektor-Koinzidenzdaten aus drei Messkampagnen im DP2-Framework; Diagnose von 15–50% unvollständigen Ereignissen und deren Rückführung auf die Detektorpositionierung; Massenkali-brierung an einer Drei-Alpha-Quelle ($R^2 = 0,99$); Anpassung bestehender Ein- und Zwei-Elektronen-CTMC-Codes an das Stoßsystem und Simulationen mit 10^6 Trajektorien; Beitrag von Dissoziations-Verzweignungsverhältnissen und Wirkungsquerschnitten zur internationalen KIDA-Datenbank.

AUSBILDUNG

Promotion in Astrochemie

Université Paris-Saclay, Institute of Molecular Sciences (ISMO)

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Betreuerin: Dr. Karine Béroff.

Malayalam



Muttersprache

Tamil, Hindi



Gute Kenntnisse

ZERTIFIKATE & WEITERBILDUNG

Deployable Data Analysis & AI Pipelines with HPC

Supercomputing-Akademie, HLRS

Universität Stuttgart | 09–10/2026 (**laufend**)

IBM AI Engineering Professional Certificate

Coursera

Deep Learning with PyTorch - abgeschlossen 08/2026, Credential DDDI9T0KHUJ4

Machine Learning with Python - laufend, Abschluss 09/2026

Angewandte Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH, Berlin

Weiterbildung, abgeschlossen 04/2026

Introduction to Supercomputing at JSC

Jülich Supercomputing Centre, Forschungszentrum Jülich | 11/2025

PUBLIKATIONEN

Sechs begutachtete Veröffentlichungen in Atom- und Molekülphysik / Astrochemie (2017–2020); ein erstes Manuskript aus dem Post-doc zur marinen Ökosystemmodellierung ist in Vorbereitung.

📖 Google Scholar

Forschungsprojekt – Theoretische Atomphysik

IIT Mandi (unter Dr. Hari Varma)

📅 02/2015 - 08/2015 📍 Mandi, Indien

Theoretische Atomphysik; teilweise remote.

M.Sc. in Physik

National Institute of Technology Calicut, Indien

📅 07/2012 - 12/2014 📍 Calicut, Indien

Mit Auszeichnung (CGPA 8,71/10).

Hamburg, im September 2026

B.Sc. in Physik

University of Calicut, Indien

📅 06/2009 - 04/2012 📍 Thrissur, Indien

B+ (CGPA 3,49/4,0).



Dr. Thejus Mahajan